

Inteligência Artificial Colaborativa na Saúde: Desafios de Acurácia e Integração de Dados

**Investigando o uso de Aprendizado Federado e RAG
em bases de dados fragmentadas e heterogêneas.**

Jacqueline Abreu do N. T. R. Lopes

Trabalho de Conclusão de Curso
MBA em Inteligência Artificial e Big Data

UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

**Inteligência Artificial Colaborativa na Saúde:
Desafios de Acurácia e Integração de Dados**

Jacqueline Abreu do N. T. R. Lopes

Jacqueline Abreu do N. T. R. Lopes

Jacqueline Abreu do N. T. R. Lopes

**Inteligência Artificial Colaborativa na Saúde:
Desafios de Acurácia e Integração de Dados:**
Investigando o uso de Aprendizado Federado e Geração
Aumentada de Recuperação (RAG) em Bases de Dados
Fragmentadas e Heterogêneas.

Trabalho de conclusão de curso apresentado ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial.

Orientadora: Profa. Dra. Agma M. Traina

Resumo

LOPES, J. A. N. T. R. **Inteligência Artificial Colaborativa na Saúde: Desafios de Acurácia e Integração de Dados**. 2026. Trabalho de Conclusão de Curso (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

A gestão de dados em saúde enfrenta desafios críticos de fragmentação, heterogeneidade e privacidade, dificultando a predição de desfechos clínicos a partir de prontuários eletrônicos (EHR). Este trabalho investiga a viabilidade de combinar Aprendizado Federado (FL) e Geração Aumentada de Recuperação (RAG) para prever trajetórias clínicas em bases de dados não padronizadas e distribuídas entre múltiplas instituições. Utilizando o repositório FAPESP COVID-19 Data Sharing/BR, que reúne dados anonimizados de cinco instituições brasileiras, propõe-se uma arquitetura de três camadas: (1) dados distribuídos mantidos localmente em cada hospital, (2) treinamento federado com o algoritmo FedProx e modelo BEHRT simplificado para processamento de sequências clínicas, e (3) justificativa diagnóstica interpretável via RAG com ChromaDB e DistilGPT-2. Cinco experimentos foram planejados para mapear desafios de padronização, avaliar o efeito equalizador do FL em instituições com poucos dados, investigar o impacto da heterogeneidade não-IID na convergência, analisar a contribuição do RAG na redução de incertezas diagnósticas e sintetizar a eficiência operacional da rede. Os resultados esperados indicam que o FL permite que hospitais com menor volume de dados alcancem performance comparável ao treinamento centralizado, enquanto o RAG oferece justificativas fundamentadas em evidências que reduzem alucinações da IA e a carga cognitiva médica. O trabalho contribui para a literatura de IA em saúde ao propor uma solução escalável, privativa e interpretável para ambientes hospitalares reais brasileiros, em conformidade com a LGPD.

Palavras-chave: Aprendizado Federado. Geração Aumentada de Recuperação. Prontuário Eletrônico. Big Data em Saúde. Inteligência Artificial.

Abstract

LOPES, J. A. N. T. R. **Collaborative Artificial Intelligence in Healthcare: Accuracy and Data Integration Challenges**. 2026. Monograph (MBA in Artificial Intelligence and Big Data) – Institute of Mathematical and Computer Sciences, University of São Paulo, São Carlos, 2026.

Healthcare data management faces critical challenges regarding fragmentation, heterogeneity, and privacy, hindering the prediction of clinical outcomes from electronic health records (EHR). This work investigates the feasibility of combining Federated Learning (FL) and Retrieval-Augmented Generation (RAG) to predict clinical trajectories in non-standardized databases distributed across multiple institutions. Using the FAPESP COVID-19 Data Sharing/BR repository, which gathers anonymized data from five Brazilian institutions, a three-layer architecture is proposed: (1) locally distributed data kept at each hospital, (2) federated training with the FedProx algorithm and a simplified BEHRT model for clinical sequence processing, and (3) interpretable diagnostic justification via RAG with ChromaDB and DistilGPT-2. Five experiments were designed to map standardization challenges, evaluate the equalizing effect of FL on data-scarce institutions, investigate the impact of non-IID heterogeneity on convergence, analyze RAG's contribution to reducing diagnostic uncertainty, and synthesize the operational efficiency of the network. Expected results indicate that FL enables hospitals with smaller data volumes to achieve performance comparable to centralized training, while RAG provides evidence-based justifications that reduce AI hallucinations and physicians' cognitive load. This work contributes to the AI in healthcare literature by proposing a scalable, privacy-preserving, and interpretable solution for real Brazilian hospital environments, in compliance with LGPD.

Keywords: Federated Learning. Retrieval-Augmented Generation. Electronic Health Record. Big Data in Healthcare. Artificial Intelligence.

TABELA DE SIGLAS

Sigla	Significado	Descrição no Contexto do Texto
BEHRT	<i>BERT for Electronic Health Records</i>	Modelo baseado em Transformers para processar registros de saúde e prever doenças futuras.
EHR	<i>Electronic Health Records</i>	Prontuário Eletrônico do Paciente; base de dados digital do histórico clínico.
FL	<i>Federated Learning</i>	Aprendizado Federado; técnica de IA onde o modelo é treinado em várias instituições sem compartilhar dados que possam conter identificação pessoal.
LGPD	Lei Geral de Proteção de Dados	Legislação brasileira que regula o tratamento de dados pessoais, inclusive na saúde.
LLM	<i>Large Language Model</i>	Grandes modelos de linguagem (como o GPT) usados para processar e gerar textos médicos.
LSTM	<i>Long Short-Term Memory</i>	Tipo de rede neural (Deep Learning) especializada em aprender dependências em dados sequenciais.

RAG	<i>Retrieval-Augmented Generation</i>	Geração Aumentada de Recuperação; técnica que consulta bases de dados externas para tornar as respostas da IA mais precisas.
RETAIN	<i>REverse Time Attentlonal Neural Networks</i>	Modelo de rede neural que analisa o histórico do paciente em ordem temporal reversa para garantir interpretabilidade.

Glossário

Termo	Definição Contextual
Prontuários eletrônicos (EHR)	Dados individuais do paciente
Registros laboratoriais	Resultados de exames específicos
Sequências clínicas	Dados temporais do histórico do paciente (usado com BEHRT/RETAIN)
Desfechos (<i>outcomes</i>)	Resultados finais dos tratamentos (variável-alvo)
Variáveis	Em contexto estatístico/metodológico
<i>Features</i> / Características	Em contexto de ML (ex: "features extraídas dos EHR")
<i>Embeddings</i>	Representações vetoriais dos dados (camada do BEHRT)
Parâmetros	Pesos do modelo treinado (não são dados, mas frequentemente confundidos)
Gradientes	Atualizações enviadas no FL (também não são dados brutos)

Bases de Dados:

- FAPESP COVID-19 Data Sharing/BR,"
Sharing2022.<https://repositoriodatasharingfapesp.usp.digital.usp.br>

SUMÁRIO

- **1 INTRODUÇÃO**

- 1.1 Contextualização, Motivação e Lacunas de Pesquisa

- 1.2 Hipótese e Objetivos

- 1.2.1 Hipótese

- 1.2.2 Possibilidades de avaliação suportadas pelo objetivo e pela hipótese

- **2 REVISÃO BIBLIOGRÁFICA**

- **3 METODOLOGIA E DESENVOLVIMENTO**

- 3.1 Visão geral da abordagem

- 3.2 Base de dados real: FAPESP COVID-19 Data Sharing/BR

- 3.2.1 Origem e estrutura

- 3.2.2 Volume e diversidade dos dados

- 3.2.3 Heterogeneidade e necessidade de normalização

- 3.2.4 Considerações finais sobre a base

- 3.3 Pré-processamento e padronização (Experimento 1)
- 3.4 Arquitetura do Aprendizado Federado
 - 3.4.1 Framework e estratégia de agregação
 - 3.4.2 Clientes e rodadas de comunicação
- 3.5 Modelo base: BEHRT simplificado
- 3.6 Integração do RAG para justificativa diagnóstica
 - 3.6.1 Construção da base de conhecimento
 - 3.6.2 Recuperação e geração
- 3.7 Experimentos e métricas de avaliação
- 3.8 Ambiente experimental e ferramentas
- 3.9 Limitações da metodologia
- 4 - REFERÊNCIAS

1 - INTRODUÇÃO

Atualmente, a análise de prontuários eletrônicos (EHR) ocorre de forma majoritariamente retrospectiva, na qual o profissional de saúde avalia o histórico para compreender o estado presente do paciente. No entanto, existe um desafio crítico em antecipar a evolução do quadro clínico de forma preditiva. Na medicina, o estado do paciente pode apresentar alterações dinâmicas e não previamente documentadas. Como os registros de saúde (exames, sinais vitais e intervenções) ocorrem em intervalos de tempo irregulares e fragmentados, se pudermos ter ferramentas que indiquem possibilidades e confirmem o prognóstico com base nos resultados dos testes, podemos obter melhores resultados nos tratamentos médicos.

O problema escolhido para investigação é a dificuldade de prever desfechos clínicos futuros a partir do processamento desses dados sequenciais complexos, que muitas vezes apresentam lacunas temporais e alta variabilidade biológica, e de propor hipóteses que indiquem possíveis evoluções do quadro do paciente.

Dentre as várias dificuldades, temos o desafio de obter dados de forma anonimizada e de múltiplas fontes de forma segura.

Neste contexto, temos a oportunidade de tentar obter informações com maior quantidade de fontes e maior quantidade de extração de dados através da Inteligência Artificial e dos mecanismos de *Federated Learning* e outras técnicas.

1.1 Contextualização, Motivação e Lacunas de Pesquisa

A gestão de dados em saúde é um fator estratégico para a eficiência hospitalar e para a segurança do paciente. É fundamental que as instituições consigam transformar o grande volume de informações coletadas em inteligência capaz de otimizar o cuidado do paciente.

A infraestrutura de dados em saúde em geral não costuma ter muita integração, o que dificulta o acompanhamento contínuo. Fatores como a privacidade do paciente e também a conectividade do local onde o paciente está têm impacto para obtermos melhores soluções para prever as possibilidades de avanço do quadro do paciente e se preparar para isso. Neste contexto, a capacidade de identificar padrões de similaridade entre pacientes — mesmo quando seus dados estão dispersos em diferentes instituições — emerge como um desafio central, tanto do ponto de vista técnico quanto ético-regulatório.

A similaridade de dados em saúde refere-se à identificação de correspondências entre perfis clínicos, seja por meio de comparação direta de variáveis (sintomas, exames, demografia), seja por meio de representações vetoriais em espaços de alta dimensionalidade gerados por modelos de aprendizado profundo. No entanto, quando os dados estão fragmentados em múltiplos hospitais, a validação dessa similaridade torna-se problemática: não é possível centralizar os prontuários para comparação direta sem violar a privacidade, e as diferenças de padronização entre instituições podem gerar falsas dissimilaridades ou, inversamente, mascarar diferenças clínicas relevantes.

Algumas possibilidades trazidas pela inteligência artificial para serem aplicadas são:

- Modelos de *Deep Learning* (*Transformers* e LSTMs): Por meio do histórico sequencial, detectam padrões de evolução e os utilizam para projetar trajetórias futuras.
- Detecção de Anomalias: Utilizar os modelos treinados para disparar alertas quando o caminho clínico do paciente se desvia do padrão esperado para uma recuperação saudável.
- Agentes Inteligentes: Utilizam o conhecimento extraído de bases de dados globais para sugerir ajustes otimizados no plano de tratamento em tempo real. Neste contexto, a proposta é que sirva como Sistemas de Apoio à Decisão, dado que um humano terá a decisão final.
- Aprendizado Federado (*Federated Learning*): forma de obter dados através do compartilhamento de informações provenientes de bases de dados de diversas instituições. Os registros obtidos podem ser usados para treinar modelos que terão diversas finalidades.

- *Retrieval-Augmented Generation* (RAG): para apoiar os agentes na sumarização dos dados obtidos por meio do aprendizado federado e no processamento por agentes inteligentes.

Exemplos de efeitos positivos da abordagem incluem: diminuição de eventos adversos, maior previsibilidade de ocupação hospitalar, redução da carga cognitiva dos médicos e maior adaptabilidade do tratamento às mudanças do quadro clínico. A maior dificuldade para a aplicabilidade dos elementos acima são a qualidade dos dados e a irregularidade temporal dos registros.

Apesar de todas as possibilidades positivas, o formato dos dados disponibilizados não apresenta uma padronização. Sem essa padronização, as fontes podem se tornar inviáveis para serem utilizadas pelas técnicas de extração e consolidação de dados. Existem diferentes protocolos de proteção de dados ao redor do mundo, o que dificulta que dados extremamente importantes sejam compartilhados. Existem diferentes formatos de unidades de dados utilizados como referência para avaliação dos mesmos quadros clínicos. Fora isso, existe o tempo de atualização das bases de dados. Esses elementos impactam significativamente a qualidade dos resultados das ferramentas baseadas em técnicas de Inteligência Artificial.

1.2 Hipótese e Objetivos

O objetivo geral é investigar a viabilidade de Aprendizado Federado (FL) associado à Geração Aumentada de Recuperação (RAG) fornecer possíveis evoluções das trajetórias clínicas, avaliando especificamente como a colaboração entre instituições pode mitigar a dificuldade de acesso a dados sensíveis e quais os desafios para garantir a acurácia das predições em bases de dados fragmentadas, não padronizadas ou heterogêneas.

1.2.1 Hipótese

A hipótese central é que o uso de **Aprendizado Federado** permite que hospitais com acesso de dados limitados se tiverem acesso a dados e aprenderem com a diversidade de uma rede global, com o suporte de RAG pode reduzir a incerteza diagnóstica ao fundamentar as predições do modelo federado em evidências clínicas recuperadas de casos historicamente similares e dessa forma, sugerir diagnósticos ao fundamentar predições em evidências clínicas distribuídas.

1.2.2 Possibilidades de avaliação suportadas pelo objetivo e pela hipótese:

- **Mapear os desafios de obtenção e padronização de dados:** Analisar as barreiras técnicas e regulatórias (como a LGPD - Lei Geral de Proteção de Dados) na extração de informações de múltiplas fontes e a necessidade de normalização para tornar os dados interoperáveis em uma rede federada.
- **Avaliar o "Efeito Equalizador" do Aprendizado Federado:** Comparar a performance (via métrica AUC-ROC) de modelos treinados isoladamente em silos locais com o modelo global federado, focando no ganho de precisão para instituições com menor volume de dados.
- **Investigar os gargalos de acurácia em dados heterogêneos:** Identificar como disparidades demográficas ou clínicas (distribuição não-IID - não independentemente e identicamente distribuída) entre hospitais impactam a convergência do modelo e podem gerar quedas de performance em casos de perfis clínicos singulares.
- **Analisar a contribuição do RAG na redução de incertezas:** Avaliar como a recuperação de documentos locais e literatura médica pode fornecer justificativas interpretáveis para o médico, ajudando a evitar alucinações da IA e reduzindo a carga cognitiva no processo de tomada de decisão.
- **Sintetizar a eficiência operacional da rede:** Determinar o ponto ótimo de convergência do treinamento federado (hiperparâmetro t) para equilibrar o ganho preditivo com o custo de comunicação entre as partes

2 - REVISÃO BIBLIOGRÁFICA

Este tema foi fundamentado inicialmente na observação do artigo de **Linhares et al. (2023)**, que apresenta o **ClinicalPath**, uma ferramenta de visualização concebida para rastrear longitudinalmente a trajetória clínica do paciente. O uso de metáforas visuais e símbolos simplificados nesta ferramenta permite que o médico identifique anomalias e mudanças

relevantes em exames laboratoriais de forma rápida, reduzindo a carga cognitiva e aumentando a confiança no processo de tomada de decisão clínica.

Apesar de termos acesso a base de dados utilizada pelo caso apresentado no **ClinicalPath**, obter dados pode ser um desafio. Para viabilizar a colaboração segura entre múltiplas instituições, a obra de **Rieke et al. (2020)** define o **Aprendizado Federado** como o paradigma no qual os dados permanecem localmente em suas origens e as suas respectivas atualizações são compartilhadas com um servidor central. Esta técnica é imprescindível para mitigar os riscos de reidentificação de pacientes e para superar os silos de dados na saúde, permitindo que o sistema aprenda com casos raros distribuídos globalmente sem violar a governança local.

Um estudo apresentado recentemente é a dissertação de **Bigoto (2025)**, adiciona fundamento ao uso de **Aprendizado Federado (FL)** em hospitais brasileiros. Este trabalho demonstra como o FL atua como um mecanismo equalizador, permitindo que hospitais com menor volume de dados alcancem ganhos expressivos de performance ao colaborarem em uma rede global. Além disso, esta abordagem valida a criação de modelos estáveis que generalizam melhor para diversas populações de pacientes, garantindo a privacidade em conformidade com a LGPD.

Com os dados obtidos de diferentes origens, temos que processar os dados obtidos de outros pacientes e do paciente avaliado. Dessa forma, precisamos de ferramentas para o processamento técnico das sequências clínicas e o modelo **RETAIN (Choi et al., 2016)** oferece o suporte necessário para garantir a **interpretabilidade** das predições. Ao mimetizar o comportamento médico, o RETAIN analisa o histórico do paciente em ordem temporal reversa, o que permite identificar quais visitas e variáveis passadas (como um diagnóstico específico) foram determinantes para a hipótese de evolução sugerida.

Complementarmente, a aplicação da arquitetura **Transformers** via modelo **BEHRT (Li, Y et al., 2020)** é essencial para lidar com a **fragmentação e irregularidade temporal** dos registros de saúde. O BEHRT utiliza *embeddings* de idade e posição para capturar a evolução biológica do paciente, permitindo prever simultaneamente a probabilidade de centenas de condições futuras com acurácia superior à dos modelos tradicionais de *Deep Learning*.

A fim de otimizar a precisão dos agentes inteligentes e reduzir a incerteza diagnóstica, inserem-se os avanços na **Geração Aumentada de Recuperação (RAG)**. A tese de **Jiang (2024)** propõe um sistema que integra LLMs a dados distribuídos de EHR para sintetizar tendências clínicas. O uso de RAG permite que as respostas da IA sejam fundamentadas em documentos e notas clínicas reais, expondo as fontes que informaram a predição, o que reduz drasticamente o risco de alucinações e aumenta a segurança para o uso médico. Somando as contribuições para o tema, Garcia et al. (2025) apresentam o DF-RAG, um framework dual de RAG federado para aplicações médicas colaborativas, enquanto Chakraborty, Dahal e Gupta (2025) realizam um mapeamento sistemático da literatura sobre *Federated RAG*, Qian et al. (2025) apresentam o HyFedRAG, uma arquitetura focada em heterogeneidade e privacidade. consolidando as principais arquiteturas e desafios da área.

Dentre os desdobramentos recentes do Aprendizado Federado na saúde, destaca-se a preocupação com a equidade (fairness) dos modelos. Do **Carmo, Traina-Jr e Traina (2025)** propõem o *FairMed-FL*, uma arquitetura que reduz vieses preditivos entre subgrupos demográficos em exames de imagem e traz uma visão importante de como podemos ter mais dados, sem privilegiar o uso de um grupo em relação ao outro.

Por fim, o estudo de **Jung et al. (2025)** reforça que a integração entre FL e RAG é a abordagem mais escalável para modelos de linguagem médicos. Os resultados experimentais indicam que modelos treinados em ambientes federados com sistemas de RAG superam consistentemente as arquiteturas centralizadas, fornecendo uma solução que preserva a privacidade enquanto amplia a capacidade de compreensão de contextos médicos complexos

3. METODOLOGIA E DESENVOLVIMENTO

Este capítulo descreve a abordagem metodológica adotada para investigar as cinco questões de pesquisa definidas na Seção 1.2.2. Inicialmente, são apresentadas as características da base de dados real de prontuários eletrônicos utilizada como estudo de caso – a mesma empregada na validação da ferramenta ClinicalPath (Linhares et al.,

2023) – juntamente com os procedimentos de pré-processamento e padronização. Em seguida, detalha-se a arquitetura do sistema baseada em Aprendizado Federado (FL) com o algoritmo FedProx (Li, T. et al., 2020) , o modelo de deep learning BEHRT (Li et al., 2020) para processamento de sequências clínicas e a integração de um mecanismo de Geração Aumentada por Recuperação (RAG) para justificativa diagnóstica. Por fim, são especificados os cinco experimentos planejados, as métricas de avaliação e o ambiente computacional utilizado.

3.1 Visão geral da abordagem

A solução proposta combina três camadas principais:

1. Camada de dados distribuída: cada hospital (cliente) mantém seus prontuários localmente, sem compartilhamento direto de informações sensíveis. Neste trabalho, utiliza-se a base de dados real do ClinicalPath, gentilmente cedida pela orientadora. Esta base contém prontuários eletrônicos anonimizados de múltiplas instituições, refletindo a fragmentação, irregularidade temporal e heterogeneidade inerentes ao ambiente clínico real.
2. Camada de aprendizado federado: utiliza o framework Flower (Beutel et al., 2020) para orquestrar o treinamento colaborativo de um modelo global BEHRT. O algoritmo escolhido é o FedProx, por sua maior robustez a dados heterogêneos – condição típica em redes hospitalares.
3. Camada de suporte à decisão (RAG): após a predição do modelo federado, um sistema de recuperação de casos clínicos semelhantes (armazenados em uma base de conhecimento construída a partir de exemplos reais da própria base) gera uma justificativa textual interpretável, reduzindo a incerteza do diagnóstico e a carga cognitiva do médico.

O fluxo completo da arquitetura é organizado da seguinte forma:

- Hospitais (clientes) – subconjuntos distintos da base do FAPESP COVID-19 Data Sharing/BR, simulando instituições com diferentes perfis de pacientes (ex.: predominância de idosos, crianças, ou população mista).
- Modelos locais – cada hospital treina uma instância local do BEHRT; apenas os parâmetros (pesos) são enviados ao servidor central.
- Servidor central (Flower) – agrega os pesos via FedProx, produzindo um modelo global.
- Predição – o modelo global é aplicado a novos pacientes da base de teste.
- Sistema RAG – recupera casos similares da base de conhecimento (construída a partir dos próprios dados de treinamento) e gera uma justificativa.
- Médico / avaliador – recebe a predição, a justificativa e a sugestão de tratamento associada.

3.2 Base de dados real: FAPESP COVID-19 Data Sharing/BR

3.2.1 Origem e estrutura

A base de dados utilizada neste trabalho é o repositório FAPESP COVID-19 Data Sharing/BR, que também serviu como fonte para o desenvolvimento e a validação da ferramenta de visualização ClinicalPath (**Linhares et al., 2023**).

De acordo com a descrição dos autores, o repositório contém informações anonimizadas de pacientes relacionadas à COVID-19, incluindo testes clínicos, desfechos (outcomes) e dados demográficos como idade, sexo e local de nascimento. Até janeiro de 2021, o repositório reunia dados de cinco instituições de saúde brasileiras: Hospital Albert Einstein, laboratórios Fleury, Hospital Sírio-Libanês, Beneficência Portuguesa/SP e Hospital das Clínicas da Faculdade de Medicina da USP (referidos no artigo como HF1 a HF5, respectivamente).

Cada resultado laboratorial registrado contém a identificação do teste, o analito medido, os valores obtidos e de referência, e a unidade de medida.

3.2.2 Volume e diversidade dos dados

O artigo original reporta as seguintes quantidades agregadas para o conjunto de dados (considerando-se a versão de janeiro de 2021):

- Pacientes: 595.000 indivíduos provenientes das cinco instituições;
- Resultados laboratoriais: aproximadamente 32,1 milhões de registros brutos (do inglês, *result tests*);
- Tipos de teste: 2.581 identificações distintas de testes laboratoriais;
- Tipos de analito: 3.753 substâncias ou parâmetros medidos.

O repositório é mantido em atualização contínua com novas instituições e dados, sendo o seu uso autorizado para fins de pesquisa científica mediante cadastro e aprovação.

3.2.3 Heterogeneidade e necessidade de normalização

Conforme descrito pelos autores, as cinco instituições que contribuem com a base utilizam diferentes tipos de testes, analitos e terminologias, frequentemente com vocabulários e grafias divergentes (Linhares et al., 2023). Adicionalmente, os dados brutos do repositório contêm ruídos, erros de digitação, pontuação extranea e valores ausentes, o que exige um processo rigoroso de limpeza e normalização antes de qualquer análise integrada.

Os autores do ClinicalPath realizaram etapas de padronização que incluíram: unificação de nomes de testes e analitos, correção de escalas de unidades de medida, remoção de registros com informações incompletas ou inconsistentes, e descarte de testes muito raros (com volume insuficiente para estimativas). Como resultado, o número de tipos de teste foi reduzido de 2.581 para 73, e o total de resultados laboratoriais foi diminuído de mais de 32 milhões para cerca de 10 milhões de registros.

Essa heterogeneidade inerente à base – tanto na forma como os dados são registrados quanto na necessidade de interoperabilidade entre instituições – constitui um dos principais focos de investigação do Experimento 1 deste trabalho.

3.2.4 Considerações finais sobre a base

As análises subsequentes do presente trabalho valem-se da base do repositório FAPESP COVID-19 Data Sharing/BR conforme disponibilizada pela orientadora. O acesso aos dados e a condução dos experimentos respeitarão os princípios da LGPD, uma vez que se trata de informações anonimizadas e que serão tratadas exclusivamente em ambiente protegido.

A partir da descrição dos autores, não há menção explícita a um caráter “intencionalmente fragmentado” da base, tampouco a uma classificação formal de “distribuição não-IID”. No entanto, a própria necessidade de padronização e normalização relatada pelos autores evidencia que os dados brutos apresentam fragmentação e despadronização, características que serão analisadas e mensuradas empiricamente nos experimentos planejados (Seções 3.3 e 3.7).

3.3 Pré-processamento e padronização (Experimento 1)

Para atender ao primeiro ponto de investigação – “*Mapear os desafios de obtenção e padronização de dados*” – será realizado um pré-processamento sistemático da base real. As etapas incluem:

1. Detecção de formatos heterogêneos: identificação de diferentes unidades de medida (kg vs. libras, anos vs. meses) e codificações de sintomas (numéricas, strings em português/inglês).
2. Normalização:
 - Conversão de todas as idades para anos.
 - Conversão de massas para kg.
 - Mapeamento de códigos e strings para um vocabulário único (inteiros sequenciais).

3. Tratamento de valores ausentes e lacunas temporais: decisão documentada sobre imputação ou remoção de registros incompletos.
4. Geração de logs: registro de cada transformação aplicada, amostras rejeitadas e eventuais inconsistências não resolvidas.

A dificuldade e o tempo despendido nessa normalização serão registrados, servindo como indicador qualitativo dos desafios de interoperabilidade – um *insight* relevante para gestores de TI em saúde.

3.4 Arquitetura do Aprendizado Federado

3.4.1 Framework e estratégia de agregação

Utiliza-se o framework *Flower* (Beutel et al., 2020) para simular a rede federada. O servidor central coordena o treinamento seguindo o algoritmo FedProx (Li, T. et al., 2020), cuja função de custo inclui um termo proximal que penaliza atualizações muito distantes do modelo global, aumentando a estabilidade em cenários não-IID. O hiperparâmetro `proximal_mu` será fixado em 0,01 após testes preliminares (Li, T. et al., 2020).

3.4.2 Clientes e rodadas de comunicação

A base do FAPESP COVID-19 Data Sharing/BR será particionada em subconjuntos (clientes), cada um representando um hospital com perfil distinto, conforme as distribuições naturais presentes nos dados (ex.: mais idosos em um subgrupo, mais crianças em outro). O particionamento será feito de forma a respeitar a heterogeneidade original.

Cada cliente executa um cliente *Flower* que:

- Carrega seu respectivo subconjunto de dados (pré-processado).
- Inicializa o modelo com os parâmetros globais enviados pelo servidor.

- Treina localmente por 3 épocas (*batch size* = 32).
- Envia de volta os gradientes ou pesos atualizados.

Serão realizadas até 50 rodadas de comunicação, com avaliação (validação) a cada 5 rodadas. O critério de parada antecipada é a estabilização da acurácia global (variação < 0,5% em 3 rodadas consecutivas).

3.5 Modelo base: BEHRT simplificado

Optou-se por uma versão reduzida do modelo *BEHRT* (BERT for Electronic Health Records) (Li, Y. et al., 2020), mantendo sua arquitetura central de *Transformers*, porém com menor número de camadas e cabeças de atenção para viabilizar a execução em hardware limitado (notebook pessoal). A arquitetura compreende:

- Camada de *embedding*: converte eventos clínicos (índices normalizados) em vetores de dimensão 64.
- *Embedding* posicional: codifica a posição temporal (ordem do evento) com funções seno/cosseno.
- Encoder Transformer: 2 camadas, 4 cabeças de atenção, *feed-forward* de 128 neurônios.
- Camada de classificação: *pooling* da saída seguido por um MLP de duas camadas (64 → 2 neurônios para classificação binária, ou número de classes conforme os desfechos da base).

O modelo é implementado em PyTorch e treinado com otimizador Adam (*learning rate* = 0,001) e função de perda de entropia cruzada.

3.6 Integração do RAG para justificativa diagnóstica

O FL garante que o modelo preditivo (**BEHRT**) seja treinado com a diversidade de toda a rede hospitalar, superando a escassez de dados de instituições isoladas. O **RAG**, por sua vez, atua na camada de inferência: dada uma predição do modelo federado, recupera casos clínicos historicamente similares da base de conhecimento local, fornecendo ao **LLM (DistilGPT-2)** um contexto factual que reduz alucinações e permite ao médico ter mais garantias em relação à justificativa. As duas técnicas são complementares, pois o FL melhora a acurácia estatística da predição e o RAG melhora a confiabilidade clínica da explicação

3.6.1 Construção da base de conhecimento

A base de conhecimento do RAG é composta por perfis clínicos prototípicos, não por prontuários individuais. Esses perfis são derivados estatisticamente do modelo BEHRT treinado via FL, representando os padrões de sintomas, demografia e evolução mais frequentemente associados a cada desfecho na rede federada.

O processo de construção segue as etapas:

1. Extração de padrões: Após a convergência do FL, o modelo global BEHRT é analisado para identificar quais combinações de *features* (sintomas, exames, idade) têm maior peso atencional na predição de cada desfecho.
2. Sintetização: Para cada desfecho, geram-se até 50 perfis prototípicos que maximizam a atenção do modelo, garantindo cobertura de subgrupos demográficos (idosos, adultos, crianças).
3. Anonimização estrutural: Remoção de todos os identificadores, datas exatas, instituições de origem e valores numéricos que permitam reidentificação (ex.: substituição de "idade 67 anos" por "faixa etária 60–70 anos").

4. Vetorização: Inserção dos documentos textuais em ChromaDB, com embeddings de 384 dimensões gerados pelo modelo all-MiniLM-L6-v2 (Reimers & Gurevych, 2019).

Essa abordagem garante que o RAG nunca acesse dados sensíveis de pacientes reais, operando exclusivamente sobre conhecimento médico generalizado aprendido colaborativamente pela rede federada.

3.6.2 Recuperação e geração

Dado um novo paciente (amostra de teste):

1. O modelo federado produz uma predição (ex.: “pneumonia” com probabilidade 0,87).
2. A lista de sintomas do paciente é convertida em uma *query* textual (ex.: “febre, tosse seca, saturação 92%”).
3. O mecanismo de recuperação busca os `top-k = 3` documentos mais similares na base (distância cosseno).
4. Um LLM leve – `distilgpt2` da *Hugging Face* – gera uma justificativa de uma frase, condicionada aos casos recuperados e à predição do modelo. O prompt utilizado é:
“Com base nos seguintes casos clínicos semelhantes: [caso1] [caso2] [caso3], o modelo previu DIAGNÓSTICO X para o paciente com sintomas [sintomas]. Justifique brevemente:”
5. A justificativa gerada é apresentada juntamente com os casos recuperados, permitindo ao avaliador verificar a procedência da explicação.

3.7 Experimentos e métricas de avaliação

Os cinco experimentos a seguir são executados sobre a base real FAPESP COVID-19 Data Sharing/BR, particionada conforme descrito, variando-se apenas o cenário de treinamento e/ou a ativação do RAG.

Experimento 1 – Desafios de padronização

- Procedimento: executa-se o pré-processamento da Seção 3.3, registrando as inconsistências detectadas e o tempo necessário para normalização.
- Métricas (qualitativas): número de transformações aplicadas, percentual de amostras rejeitadas, dificuldade de automação.

Experimento 2 – Efeito equalizador do FL

- Cenários:
 - *Local*: cada hospital treina seu modelo isoladamente (sem comunicação).
 - *Federado*: os subconjuntos colaboram via FedProx.
- Métrica principal: AUC-ROC (Área sob a Curva ROC) para cada subconjunto em cada cenário.
- Análise: compara-se o ganho relativo do subconjunto com menor volume de dados frente aos demais.

Experimento 3 – Impacto da heterogeneidade (não-IID) na convergência

- Procedimento: treina-se o modelo federado com a distribuição natural não-IID da base. Como contraste, cria-se uma versão balanceada (misturando os registros) para simular um cenário IID.
- Métricas: acurácia por subgrupo demográfico (ex.: idosos vs. crianças) ao longo das rodadas; diferença de acurácia entre os subgrupos no modelo final.
- Análise: verifica-se se o modelo apresenta viés contra o subgrupo minoritário em cada hospital.

Experimento 4 – Contribuição do RAG na redução de incertezas

- Procedimento: para 50 amostras de teste (selecionadas aleatoriamente), um avaliador (o próprio autor ou um colega simulando o papel do médico) classifica a justificativa gerada em uma escala Likert de 1 (inútil/alucinação) a 5 (totalmente clara e correta).

- Métrica: percentual de justificativas com nota ≥ 4 (consideradas úteis).
Adicionalmente, registra-se a frequência de “alucinações” (justificativas contraditórias à predição).
- Análise qualitativa: exemplos de justificativas bem-sucedidas e mal-sucedidas são discutidos.

Experimento 5 – Eficiência operacional da rede

- Procedimento: durante o treinamento federado, registra-se a acurácia de validação a cada rodada e o volume de dados transmitidos (estimado pelo tamanho serializado dos parâmetros do modelo – aproximadamente 2 MB por rodada para o BEHRT simplificado).
- Métricas:
 - Acurácia global ao final de cada rodada.
 - Custo acumulado de comunicação (MB) vs. acurácia.
 - Rodada de convergência T_{opt}: primeira rodada após a qual o incremento de acurácia é $< 0,5\%$ por 3 rodadas consecutivas.
- Análise: recomenda-se um ponto de parada prático para minimizar recursos sem perda significativa de desempenho.

3.8 Ambiente experimental e ferramentas

Todos os experimentos serão executados em hardware a ser definido. O software utilizado compreende:

- Linguagem: Python 3.10.
- Bibliotecas principais:
 - Aprendizado federado: flwr (Flower)
 - Deep learning: torch, transformers
 - Dados: pandas, numpy, datasets
 - RAG: langchain, chromadb, sentence-transformers
 - Métricas: scikit-learn
- Controle de versão: Git + GitHub.

O código fonte do protótipo será disponibilizado em repositório público, com instruções para reprodução dos experimentos. Para o desenvolvimento dos experimentos, será utilizada a biblioteca *Transformers* (Wolf et al., 2020) da *Hugging Face*, juntamente com o *framework* PyTorch (Paszke et al., 2019).

3.9 Limitações da metodologia

Reconhecem-se as seguintes limitações do projeto proposto para ser desenvolvido nas próximas interações:

- Escopo da base de dados: embora real, a base do ClinicalPath pode não representar toda a diversidade de prontuários eletrônicos brasileiros (ex.: diferentes sistemas hospitalares). Os resultados, portanto, são específicos a este *dataset*, mas o método é generalizável.
- Modelo BEHRT simplificado: a versão reduzida pode sacrificar desempenho em comparação com o BEHRT original. Justifica-se pelo hardware disponível e pelo caráter de prova de conceito.
- RAG com LLM pequeno: *distilgpt2* da *Hugging Face* (Sanh et al., 2019), tem capacidade limitada de geração; justificativas podem ser repetitivas ou vagas. Em um cenário real, recomenda-se um LLM maior ou ajustado para domínio médico (ex.: BioGPT, LLaMA-med).
- Simulação de médicos: a avaliação qualitativa do RAG será feita pelo próprio autor (e eventualmente um colega), não por profissionais de saúde com experiência clínica. Futuros trabalhos devem incluir validação com médicos reais.
- Privacidade e segurança: os dados reais são anonimizados e tratados em ambiente seguro. O uso de aprendizado federado adiciona uma camada extra de proteção, mas não elimina completamente riscos residuais (ex.: inferência de atributos). Este trabalho não implementa privacidade diferencial, deixando-a como trabalho futuro.

4 - REFERÊNCIAS

BEUTEL, D. J. et al. Flower: a friendly federated learning research framework. arXiv:2007.14390, 2020. Disponível em: <https://arxiv.org/abs/2007.14390>. Acesso em: 20 maio 2026.

BIGOTO, M. A. R. Uso de aprendizado federado em amostras multicêntricas de hospitais para a predição de óbitos de pacientes hospitalizados com COVID-19. 2025. Dissertação (Mestrado em Ciências de Computação) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

CHAKRABORTY, A.; DAHAL, C.; GUPTA, V. Federated Retrieval-Augmented Generation: a systematic mapping study. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 2025, Miami. **Findings of the Association for Computational Linguistics: EMNLP 2025**. [S.l.]: ACL, 2025. p. 7362-7374.

CHOI, E. et al. RETAIN: an interpretable predictive model for healthcare using reverse time attention mechanism. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 29., 2016. **Advances in Neural Information Processing Systems 29**. [S.l.: s.n.], 2016. p. 3504-3512.

DO CARMO, Ê. P.; TRAINA-JR, C.; TRAINA, A. J. M. FairMed-FL: federated learning for fair and unbiased deep learning in medical imaging. In: IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS, 38., 2025, Madrid. **Proceedings...**. [S.l.]: IEEE, 2025. p. 1-6. <https://doi.org/10.1109/CBMS61543.2025.00142>.

GARCIA, J. et al. DF-RAG: a dual federated retrieval-augmented generation framework for collaborative medical AI. In: ACM/IEEE INTERNATIONAL CONFERENCE ON CONNECTED HEALTH: APPLICATIONS, SYSTEMS AND ENGINEERING TECHNOLOGIES, 2025. **Proceedings...**. [S.l.: s.n.], 2025.

JIANG, E. Clinical question-answering over distributed EHR data. 2024. Dissertação (Mestrado) – Massachusetts Institute of Technology, Cambridge, 2024.

JUNG, J.; JEONG, H.; HUH, E. N. Federated Learning and RAG integration: a scalable approach for medical large language models. In: IEEE INTERNATIONAL CONFERENCE ON UBIQUITOUS COMPUTING AND COMMUNICATIONS, 2025. ****Proceedings...**** [S.l.: s.n.], 2025.

LI, T. et al. Federated optimization in heterogeneous networks. In: CONFERENCE ON MACHINE LEARNING AND SYSTEMS, 3., 2020. ****Proceedings of Machine Learning and Systems****. [S.l.: s.n.], 2020. v. 2.

LI, Y. et al. BEHRT: transformer for electronic health records. ****Scientific Reports****, v. 10, n. 1, p. 1-12, 2020. <https://doi.org/10.1038/s41598-020-62922-y>.

LINHARES, C. D. G. et al. ClinicalPath: a visualization tool to improve the evaluation of electronic health records in clinical decision-making. ****IEEE Transactions on Visualization and Computer Graphics****, v. 29, n. 10, p. 4031-4046, 2023. <https://doi.org/10.1109/TVCG.2023.3283526>.

PASZKE, A. et al. PyTorch: an imperative style, high-performance deep learning library. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 32., 2019, Vancouver. ****Advances in Neural Information Processing Systems 32****. [S.l.]: Curran Associates, 2019.

QIAN, C. et al. HyFedRAG: a federated retrieval-augmented generation framework for heterogeneous and privacy-sensitive data. arXiv:2509.06444, 2025. Disponível em: <https://arxiv.org/abs/2509.06444>. Acesso em: 20 maio 2026.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: sentence embeddings using Siamese BERT-Networks. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING, 2019, Hong Kong. ****Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing****. Stroudsburg: ACL, 2019.

RIEKE, N. et al. The future of digital health with federated learning. ****npj Digital Medicine****, v. 3, n. 1, p. 119, 2020.

SANH, V. et al. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108, 2019. Disponível em: <https://arxiv.org/abs/1910.01108>. Acesso em: 20 maio 2026.

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., Drame, M., Lhoest, Q., & Rush, A. M. (2020).

HuggingFace's Transformers: State-of-the-art Natural Language Processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (pp. 38–45). Association for Computational Linguistics.